

TP Inicial

Alan Erdei, Nicolás Ian Rozenberg, Mateo Suffern

2024-03-29

```
# Librería utilizada para realizar bagplot  
library(aplpack)  
library(ggplot2)
```

Carga y preparación de los datos

```
datos_encuesta <- read.table("./ENNyS_menorA2.txt", header = TRUE)  
head(datos_encuesta)
```

```
##      Sexo Tipo_embarazo      Edad  Peso Perim_encef Talla  
## 1 Varon      Simple 1.84109589 14.48      50.0  87.5  
## 2 Mujer      Simple 1.49589041 11.88      47.5  76.7  
## 3 Mujer      Simple 0.58082192  6.78      42.0  69.0  
## 4 Mujer      Simple 0.07945205  4.18      37.8  49.9  
## 5 Varon      Simple 1.64931507 11.68      48.1  83.7  
## 6 Mujer      Simple 0.05479452  3.98      36.0  52.0
```

Cambiamos el tipo de las columnas Sexo y Tipo_embarazo a factor (categórico)

```
datos_encuesta$Sexo <- as.factor(datos_encuesta$Sexo)  
datos_encuesta$Tipo_embarazo <- as.factor(datos_encuesta$Tipo_embarazo)  
attach(datos_encuesta)
```

Ejercicio 1

```
perim_encef_hist <- hist(  
  Perim_encef,  
  probability = TRUE,  
  main="Histograma de perimetro encefalico comparado con densidades estimadas",  
  xlab="Perimetro encefalico (cm)",  
  ylab="Densidad",  
  ylim=c(0, 0.15)  
)
```

```


kernels <- c("gaussian", "epanechnikov", "rectangular")
colors <- c("red", "blue", "green")
kde_perim_encef <- list() # A ser utilizado en siguientes ejercicios

for (i in seq_along(kernels)) {
  kde <- density(
    Perim_encef,
    kernel = kernels[i]
  )
  lines(kde, col = colors[i], lw = "2")
  kde_perim_encef[[kernels[i]]] <- kde
}

legend(x="topleft", legend = kernels, col = colors, lty = 1:3)

```

Histograma de perímetro encefálico comparado con densidades estim:



Se puede observar que la densidad estimada por cada uno de los núcleos proporcionados ajustan de forma muy similar y que se asimilan al histograma. Sin embargo, el histograma no recopila la información de que para valores considerablemente cercanos a 50, la densidad disminuye rápidamente hasta 0.

Ejercicio 2

Primero, verificamos que no hayan registros de bebés de edad mayor a 2 años

```
sum(Edad > 2)
```

```
## [1] 0
```

No los hay. Estimamos la probabilidad de que el perímetro encefálico se encuentre en el rango de 42 cm a 48 cm primero aproximando la integral de la densidad estimada con el kernel Epanechnikov

```
lower_bound <- 42  
upper_bound <- 48
```

```
bw <- kde_perim_encef$epanechnikov$bw
```

```
prob_estim_epa <- function(datos, h, x){  
  n <- length(datos)  
  u <- (x - datos)/h  
  return((3/(4*n)) * sum(  
    (u - (u^3)/3 + (2/3)) * (abs(u) <= 1)  
    + (4/3) * (u > 1)  
  ))  
}
```

```
prob_res <- prob_estim_epa(  
  Perim_encef,  
  bw,  
  upper_bound  
) - prob_estim_epa(  
  Perim_encef,  
  bw,  
  lower_bound  
)  
cat("Probabilidad integrando densidad estimada:", prob_res)
```

```
## Probabilidad integrando densidad estimada: 0.5795061
```

Ahora utilizando tanto los datos arrojados por el histograma. Primero, observamos que los límites se encuentran en los últimos dos bins.

```
perim_encef_hist$breaks
```

```
## [1] 10 15 20 25 30 35 40 45 50
```

```
nbins <- length(perim_encef_hist$density)  
prob_estim_hist <- (  
  perim_encef_hist$density[nbins-1] * (45-42)  
  + perim_encef_hist$density[nbins] * (48-45)  
)  
cat("Probabilidad obtenida mediante histograma:", prob_estim_hist)
```


```
## Probabilidad obtenida mediante histograma: 0.5233615
```

Ejercicio 3

Graficamos las densidades estimadas utilizando tanto el doble de ventana, como la mitad.

```
for (i in seq_along(kernels)) {  
  kde <- density(  
    Perim_encef,  
    kernel = kernels[i],  
    adjust = 1/2  
  )  
  
  if (i == 1){  
    plot(  
      kde,  
      col = colors[i],  
      main = sprintf("Densidad estimada con ventana %f", kde$bw),  
      xlab="Perimetro encefalico (cm)",  
      ylab="Densidad"  
    )  
  }  
  else{  
    lines(  
      kde,  
      col = colors[i],  
      lw = "2"  
    )  
  }  
}  
  
legend(x="topleft", legend = kernels, col = colors, lty = 1:3)
```


Densidad estimada con ventana 0.292076



```
for (i in seq_along(kernels)) {
  kde <- density(
    Perim_encef,
    kernel = kernels[i],
    adjust=2
  )

  if (i == 1){
    plot(
      kde,
      col = colors[i],
      main = sprintf("Densidad estimada con ventana %f", kde$bw),
      xlab="Perimetro encefalico (cm)",
      ylab="Densidad"
    )
  }
  else{
    lines(
      kde,
      col = colors[i],
      lw = "2"
    )
  }
}

legend(x="topleft", legend = kernels, col = colors, lty = 1:3)
```



Se puede observar que la densidad estimada con una ventana de la mitad del tamaño que la primera, la densidad es mucho más fluctuante que en el caso de la ventana de tamaño doble. Esto puede deberse a que para cada punto en el eje x hay menor cantidad de datos que se encuentren a distancia de una ventana, y por lo tanto más variable.

Ejercicio 4

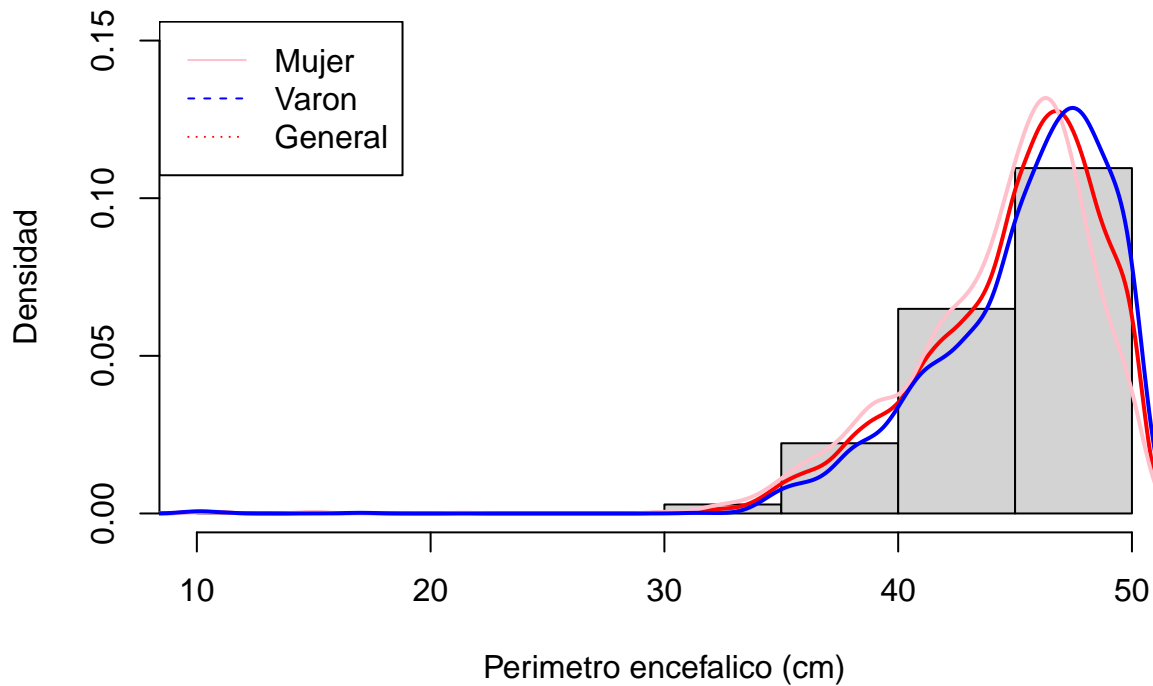
```
hist(Perim_encef,
     probability = TRUE,
     main = "Histograma comparado con densidades de acuerdo al sexo",
     xlab="Perimetro encefalico (cm)",
     ylab="Densidad",
     ylim=c(0, 0.15)
)
lines(
  kde_perim_encef[["gaussian"]],
  col = "red",
  lw = "2"
)
sexos <- c("Mujer", "Varon")
colors <- c("pink", "blue")
for (i in seq_along(sexos)){
```

```

kde <- density(
  Perim_encef[Sexo == sexos[i]],
  kernel = "gaussian",
)
lines(
  kde,
  col = colors[i],
  lw = "2"
)
}
legend(x="topleft", legend = c(sexos, "General"), col = c(colors, "red"),lty = 1:3)

```

Histograma comparado con densidades de acuerdo al sexo



Se puede observar que el perímetro encefálico tiende a ser de menor longitud que el de los varones, puesto que la curva de densidad estimada para las mujeres es más alta para valores más pequeños.

Ejercicio 5

```


hist(
  Perim_encef,
  probability = TRUE,
  main = "Histograma comparado con densidades",
  xlab="Perimetro encefalico (cm)",
  ylab="Densidad",
  ylim=c(0, 0.15)
)

```

```

)
lines(
  kde_perim_encef[["gaussian"]],
  col = "red",
  lw = "2"
)
tipos_embarazo <- c("Simple", "Multiple")
colors <- c("blue", "green")
for (i in seq_along(tipos_embarazo)){
  kde <- density(
    Perim_encef[Tipo_embarazo == tipos_embarazo[i]],
    kernel = "gaussian",
  )
  lines(
    kde,
    col = colors[i],
    lw = "2",
  )
}
legend(x="topleft", c(tipos_embarazo, "General"), col = c(colors, c("red")),lty = 1:3)

```



La densidad estimada del perímetro encefálico para los casos de nacimiento múltiple difiere considerablemente de la densidad general estimada, y la de los casos de nacimiento simple. Calculamos la frecuencia relativa de cada tipo de embarazo.


```
table(Tipo_embarazo) / length(Tipo_embarazo)
```


```
## Tipo_embarazo  
##   Multiple      Simple  
## 0.03347428 0.96652572
```

Vemos que aproximadamente el 3% de los registros provienen de embarazos múltiples, por lo que consideramos que no podemos sacar conclusiones acerca de esta diferencia.

Ejercicio 6

```
bagplot_pc_t <- bagplot(  
  Perim_encef,  
  Talla,  
  main = "Bagplot entre Perimetro encefalico y Talla",  
  xlab="Perimetro encefalico (cm)",  
  ylab="Talla (cm)"  
)
```


Bagplot entre Perimetro encefalico y Talla



Se pueden identificar fácilmente varios puntos atípicos, especialmente con perímetro encefálico chico, y tallas alrededor de la media de la talla. No necesariamente tienen talla alta en estos casos. Sí se ven tallas muy altas (Hay puntos con tallas mayores a 90 cm). También casos donde la talla es muy baja (menor a 40 cm) y un perímetro encefálico muy alto (cercano a 50 cm).

Ejercicio 7

```
bagplot_pc_t_2 <- bagplot(  
  c(bagplot_pc_t$pxy.bag[, 'x'], bagplot_pc_t$pxy.outer[, 'x']),  
  c(bagplot_pc_t$pxy.bag[, 'y'], bagplot_pc_t$pxy.outer[, 'y']),  
  main = "Bagplot entre Perimetro encefalico y Talla",  
  xlab="Perimetro encefalico (cm)",  
  ylab="Talla (cm)"  
)
```



Se visualizan datos atípicos, mas muchos menos que con los datos anteriores y más cercanos a la cápsula convexa.


Ejercicio 8

```
xlim <- c(min(Perim_encef), max(Perim_encef))  
ylim <- c(min(Talla), max(Talla))  
  
par(mfrow = c(1, 2))  
  
for (sexo in unique(Sexo)) {  
  subset_data <- datos_encuesta[Sexo == sexo, ]  
}
```

```

bagplot_pc_t <- bagplot(
  subset_data$Perim_encef,
  subset_data$Talla,
  main = sprintf("Bagplot entre Perimetro encefalico y Talla (%s)", sexo),
  xlab="Perimetro encefalico (cm)",
  ylab="Talla (cm)",
  xlim=xlim,
  ylim=ylim
)
}

```



Se puede observar que existe una distribución conjunta muy similar para ambos sexos, y la ubicación de outliers también muy similar. Parecería ser que la relación entre perímetro encefálico y talla no cambia mucho entre ambos, y que la aparición de outliers no parece depender del sexo.